

Fundamente de Big Data

Investigarea înclinației spre cumpărare în mediul online

Proiect

Student: Vișan Iulia-Raluca

Universitatea Babeș-Bolyai

Informatică economică, an 3, sem2

2026, Cluj-Napoca

Capitolul 1. Introducere

Comerțul online, zis și E-Commerce, face referire la procesul de vânzare-cumpărare dintre companii-clienți(B2C), companii-companii(B2B), și clienți-clienți(C2C), pe platformele din mediul online. Această acțiune are la bază tranzacția monetară ca mijloc de operare a bunurilor, tranzacție ce poate fi savârșită bazându-se pe criteriul încrederii și motivației, având în vedere faptul că produsele din cataloagele online nu pot fi inspectate fizic (Sotelo, 2024).

Retail-ul digital se manifestă diferit la nivel global, iar odată cu timpul au apărut diverse metode de analiză a intenției vizitatorilor de cumpărare pe Internet, metode ce pot ajuta la înțelegerea comportamentului consumatorilor și analiza prosperității sau insuccesului afacerilor.

În acest raport vor fi abordate două întrebări principale, și anume:

1. În ce măsură vor prezice variabilele de performanță ale paginilor dacă vizitatorii vor genera un venit?
2. Cum influențează profilul vizitatorului și momentul vizitei probabilitatea de a fi realizată conversia de la titlul de “simplu oaspete al site-ului” la “cumpărător”? Iar, care dintre acești factori are o importanță mai mare?

Relevanța subiectului abordat constă în dorința de a investiga acțiunile unui client care va genera profit față de cel care nu, și cât de importanți sau relevanți sunt factorii externi, precum zilele de sărbătoare sau weekend-urile. Aceste date nu doar că vor constitui o analiză, dar pot, de asemenea, contribui la îmbunătățirea site-urilor companiilor și profitul afacerilor.

În trecut, au mai existat abordări pe tematica celor două întrebări, precum cea din articolul “Real-Time Prediction of Online Shoppers’ Purchasing Intention Using Random Forest”, scris de Karim Baati și Mouad Mohsil în anul 2020. Textul are la baza obiectivul de a implementa un sistem de identificare a intenției utilizatorilor de cumpărare, imediat cum se conectează la un catalog online. Mai exact, după procesul de accesare a site-ului, potențialul cumpărător va primi oferte atractive de achiziționare a produselor, iar dacă persoana nu a fost convinsă încă, și se mai afla pe pagină, aceasta va primi oferte și mai generoase decât cele din urmă, scopul fiind de a micșora rata de părăsire a site-ului (Baati & Mohsil, 2020).

Rezultatul cercetării realizate de Baati și Mohsil, pe setul de date “Online Shoppers Purchasing Intention Dataset” de la UCI, a fost demonstrarea eficienței în timp real a algoritmilor de tip Random Forest, iar setul de date utilizat a fost fundamentat și descris inițial de Sakar et al.(2019), oferind baza pentru analiza comportamentului de navigare în timp real (Sakar, Polat, Katircioglu, & Kastro, 2019, pp. 3-4).

Capitolul 2. Setul de date

2.1. Descrierea și originea setului de date utilizat

Setul de date utilizat în acest raport poate fi regăsit sub numele de “Online Shoppers Purchasing Intention Dataset” din cadrul UCI. Acesta este propus de Sakar et al., în anul 2019, în studiul privind predicția intenției de cumpărare în timp real, din jurnalul “Neural Computing and Applications”. Setul de date conține **12 330** de sesiuni unice, **10 422** dintre acestea având un rezultat negativ, ce nu a generat un venit, în timp ce restul de **1908** au fost pozitive. Setul de date a fost construit în așa manieră, încât datele fiecărei instanțe să provină de la utilizatori unici, fiind observați de-a lungul unui an de zile (Sakar, Polat, Katircioglu, & Kastro, 2019).

Conform autorilor, această abordare a fost aleasă pentru a asigura o putere mai crescută de generalizare a rezultatelor, evitând tendințele către companii sau utilizatori specifici, fiind un mediu echilibrat de proiectare și prelucrare a datelor.

2.2. Relevanța materialului pentru întrebările alese

Corpusul de date prezent dovedește o relevanță deosebită în ceea ce privește conexiunea dintre întrebările de cercetare ale raportului și variabilele care pot fi folosite în vederea constituirii unor răspunsuri adecvate.

Când vine vorba de prima întrebare, dacă variabilele de performanță pot prezice un eventual profit din partea utilizatorului, coloanele cele mai importante în adresarea răspunsului vor fi **PageValue** și **ExitRates**. Cea dintâi menționată reprezintă valoarea medie a paginii vizitate înainte ca o tranzacție să fie finalizată. Adică, media tuturor paginilor vizitate de utilizatorul respectiv în timpul acelei sesiuni unice, stocat în aceasta variabilă.

De asemenea, **ExitRates** reprezintă media ratelor de ieșire pentru toate paginile accesate în timpul unei sesiuni unice. Practic, aceasta oferă procentul de cazuri în care o pagină vizualizată a fost ultima din sesiune, oferind posibile detalii și informații cu privire la momentul deciziv în care vizitatorul online a ales să părăsească site-ul. Este important de menționat că **ExitRates** nu este doar o cifră oarecare, ci o metrică din Google Analytics, ce se afla într-o strânsă legătură atât cu variabila **Revenue**, dar și cu **PageValue**.

A doua întrebare este adresată tipului de utilizator și momentul în care acesta se află pe site. Variabila **VisitorType** este una de tip calitativ, ce împarte utilizatorii în “New Visitor”, “Returning Visitor” și “Other”. Conform studiului lui Sakar et al.(2018), vizitatorii recurenți au o tendință mai ridicată de conversie și de creștere a profitului, dar asta nu înseamnă că utilizatorii noi nu oferă date substanțiale referitoare la tendința de cumpărare ca persoană nou-venită.

De asemenea, variabilele **Weekend** și **Month** permit să analizeze pattern-uri când vine vorba de lunile și zilele în care traficul online poate fi la cote mai ridicate, din motive diverse, precum faptul că oamenii au, în general, mai mult timp liber în weekend, sau doresc să achiziționeze ceva la un preț foarte redus de Black Friday sau alte tipuri de campanii ce pot stârni motivația oamenilor de a cumpăra produse.

Și, nu cea din urmă, o alta coloană semnificativă în setul de date prezent este numită **SpecialDay**, o atribută ce determină, în mod numeric și binar, apropierea de un eveniment special, 0 însemnând că nu se apropie nicio sărbătoare, iar 1 semnificând opusul. Aceasta a fost calculată prin luarea în calcul a unui interval de cel puțin 10 zile înainte de zilele respective.

Acestea sunt cele mai importante variabile pentru răspunsul întrebărilor de cercetare precizate în paragrafele anterioare, fiind bineînțeles însoțite de restul variabilelor din setul de date, ce vor fi dezbătute în rândurile următoare.

2.3. Caracteristicile datelor brute

Inspectarea eșantionului de lucru este un prim pas în analiza datelor și construirea răspunsurilor pentru întrebările prezentate. Așadar, în acest moment, datele sunt sub forma lor brută de după aducere a acestora în limbajul R și reflectă formatul lor nativ .csv.

Folosind funcția **skim(info_cumparatori)** din pachetul **skimr**, avem ca rezultat o scurtă descriere a setului de date curent (Fig. 1.a).

Data Summary	
	Values
Name	info_cumparatori
Number of rows	12330
Number of columns	18

Fig.1.a.

De asemenea, pentru a vizualiza detalii legate de fiecare coloană în parte, prin funcția **glimpse(info_cumparatori)**, putem obține o privire de ansamblu asupra setului brut format din **18** variabile și **12 330** de instanțe (Fig. 1.b).

```
> glimpse(info_cumparatori)
Rows: 12,330
Columns: 18
$ Administrative      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 2, 0, 0...
$ Administrative_Duration <dbl> 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0...
$ Informational      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ Informational_Duration <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ ProductRelated     <dbl> 1, 2, 1, 2, 10, 19, 1, 0, 2, 3, 3, 16, 7, 6, 2, 23, 1...
$ ProductRelated_Duration <dbl> 0.000000, 64.000000, 0.000000, 2.666667, 627.500000, ...
$ BounceRates        <dbl> 0.200000000, 0.000000000, 0.200000000, 0.050000000, 0...
$ ExitRates          <dbl> 0.200000000, 0.100000000, 0.200000000, 0.140000000, 0...
$ PageValues         <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ SpecialDay         <dbl> 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.4, 0.0, 0.8, 0.4, 0.0...
$ Month              <chr> "Feb", "Feb", "Feb", "Feb", "Feb", "Feb", "Feb", "Feb...
$ OperatingSystems   <dbl> 1, 2, 4, 3, 3, 2, 2, 1, 2, 2, 1, 1, 1, 2, 3, 1, 1, 1...
$ Browser            <dbl> 1, 2, 1, 2, 3, 2, 4, 2, 2, 4, 1, 1, 1, 5, 2, 1, 1, 1...
$ Region             <dbl> 1, 1, 9, 2, 1, 1, 3, 1, 2, 1, 3, 4, 1, 1, 3, 9, 4, 1...
$ TrafficType        <dbl> 1, 2, 3, 4, 4, 3, 3, 5, 3, 2, 3, 3, 3, 3, 3, 3, 3, 4...
$ VisitorType        <chr> "Returning_Visitor", "Returning_Visitor", "Returning...
$ Weekend            <lgl> FALSE, FALSE, FALSE, FALSE, TRUE, FALSE, FALSE, TRUE...
$ Revenue            <lgl> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALS...
```

Fig. 1.b. Date brute

Materialul empiric brut le clasifică în trei categorii R, și anume:

- 14 variabile de tip numeric <dbl>
- 2 variabile categorice <chr>
- 2 variabile logice <lgl>

La rândul lor, cele **14** variabile numerice se împart pe trei ramuri, și anume:

1. Comportament pagini :
 - 1.1. **Administrative**: numărul de pagini administrative vizitate în sesiune
 - 1.2. **Administrative_Duration**: timpul total(sec.) petrecut pe paginile administrative
 - 1.3. **Informational**: numărul de pagini informaționale vizitate în sesiune
 - 1.4. **Informational_Duration**: timpul total(sec.) petrecut pe paginile informaționale
 - 1.5. **ProductRelated**: numărul de pagini de produs vizitate în sesiune
 - 1.6. **ProductRelated_Duration**: timp total(sec.) petrecut pe paginile de produs
2. Metrice sesiune din cadrul **Google Analytics**:
 - 2.1. **BounceRates**: rata de abandon imediat în medie a paginilor vizitate
 - 2.2. **ExitRates**: rata de părăsire medie a paginilor vizitate
 - 2.3. **PageValues**: valoarea medie a paginii înainte de finalizarea tranzacției
 - 2.4. **SpecialDay**: apropierea față de o zi importantă(0/1)
3. Context demografic:
 - 3.1. **OperatingSystems**: sistemul de operare al utilizatorului(cod num.)
 - 3.2. **Browser**: browser-ul folosit de utilizator(cod num.)
 - 3.3. **Region**: regiunea geografică a oaspetelui(cod num.)
 - 3.4. **TrafficType**: tipul traficului(cod num.)

De asemenea, cele 2 variabile categorice se împart în 2 ramuri:

1. Temporale:
 - 1.1. **Month**: luna în care a avut loc sesiunea
2. Profil și context:
 - 2.1. **VisitorType**: tipul de vizitator(Returning_Visitor, New_Visitor, Other)

Iar, nu în ultimul rand, variabilele logice se împart, și ele, pe doua categorii:

1. Temporale:
 - 1.1. **Weekend**: TRUE dacă sesiunea a avut loc în weekend, FALSE dacă nu
2. Variabila țintă:

1.1. **Revenue**: TRUE dacă sesiunea a fost finalizată cu o achiziție, FALSE dacă nu

Important de menționat este faptul ca variabilele **Operating Systems**, **Browser**, **Region** și **TrafficType** au valori <dbl> în R, în setul de date brut, pe când când ele ar fi trebuit să fie recunoscute drept categorii, deoarece numerele respective nu reprezintă cantități, ci coduri numerice pentru diferite sisteme de operare, browsere, regiuni, tip de trafic. Practic, numerele acționează, în cazul acesta, pe post de “etichete”. Acestea nu sunt clare din studiul lui Sakar(2019), probabil din motive de anonimat.

Următorul subpunct al acestui subiect este integritatea datelor. Mai exact, în urma unei comenzi ajutătoare, va fi stabilit dacă există valori lipsă, iar pentru această verificare se va folosi comanda **sum(is.na())**, iar în urma rulării se poate observa faptul ca există **0** valori ce lipsesc din setul nostru de date(Fig. 2), adică **0** celule goale. Datorită acestui lucru, procesarea și analiza datelor va fi ușor de construit.

Fig. 2

```
> sum(is.na(info_cumparatori))  
[1] 0
```

Ultimul subiect de abordat în acest capitol este distribuția **clasei țintă**, și anume variabila care va dicta întregul proces de analiză a datelor: **Revenue**.

Cu ajutorul primei comenzi: **table(info_cumparatori\$Revenue)** se va afișa cu exactitate numărul de valori **FALSE(10 422)**, adică numărul de persoane care nu au generat un venit, dar și numărul valorilor **TRUE(1908)**, ce reprezintă numărul de persoane care au achiziționat ceva în sesiunea respectivă (Fig. 3).

De asemenea, pentru a avea aceste date în format procentual, va fi folosită comanda: **prop.table(table(info_cumparatori\$Revenue)) * 100** (Fig. 4).

```
> table(info_cumparatori$Revenue) > prop.table(table(info_cumparatori$Revenue)) * 100
```

FALSE	TRUE	FALSE	TRUE
10422	1908	84.52555	15.47445

Fig. 3

Fig. 4

2.4. Preprocesarea datelor

1. Primul pas în preprocesarea datelor constă în verificarea integrității eșantionului, pas amintit în subcapitolul anterior, unde am verificat dacă există valori necunoscute sau lipsă în baza noastră de date. Acest lucru a fost demonstrat prin funcția **is.na()** (Fig. 2). Dat fiind faptul că nu există astfel de divergențe, trecerea la următorul pas poate fi făcută cu ușurință, fiind capabili de a folosi întregul set de date.
2. Cel de-al doilea pas în preprocesarea informației brute este eliminarea duplicatelor. În această secvență, pentru a descoperi dacă setul de date brut are vreo instanță care se repeta, se va folosi funcția **sum(duplicated(info_cumparatori))**. În urma rulării acesteia, avem ca rezultat **125** de rânduri duplicate (Fig. 5).

Pentru a merge mai departe, va fi creat un set de date nou, pornind de la cel inițial, intitulat **info_cumparatori_curatat**. Motivul este de a stoca primul set în cel de-al doilea, și curăța datele de duplicate, ca mai apoi să fie valabile ambele seturi: cel original și cel curățat, pe care vom continua să lucrăm.

La o simplă verificare, setul **info_cumparatori_curatat** va afișa 0 instanțe ce se repetă (Fig. 6): **info_cumparatori_curatat <- info_cumparatori_curatat %>% distinct()**.

În figura 7 sunt afișate cele două seturi de date, cel original și cel prelucrat, pe care se vor realiza următorii pași de preprocesare și analiză.

```
> sum(duplicated(info_cumparatori))
[1] 125
```

Fig. 5

Data	
info_cumparatori	12330 obs. of 18 variables
info_cumparatori_curatat	12205 obs. of 18 variables

Fig.7

```
> sum(duplicated(info_cumparatori_curatat))
[1] 0
```

Fig. 6

- Al treilea pas, și cel mai important, folosit în preprocesarea datelor este transformarea tipurilor de date.

3.1. De la numericul <dbl> la Factor:

Variabilele afectate vor fi: **OperatingSystems, Browser, Region, TrafficType**.

După cum am menționat anterior, cele patru variabile nu reprezintă cantități numerice, chiar dacă se află sub eticheta <dbl>. În schimb, acestea reprezintă etichete prin coduri, nr. 1 însemnând, spre exemplu Windows, nr. 2 poate Linux, ș.a.m.d. în fiecare din aceste coloane. Însemnătatea numerelor este, din păcate, neclara în documentația oficială. Așadar, datorită schimbării în factori, R nu va încerca să creeze ierarhii, ci doar va fi clarificat faptul că acestea sunt doar etichete.

3.2. De la text <chr> la Factor:

Variabilele afectate vor fi: **Month, VisitorType**.

În formatul actual, valorile instanțelor de la aceste coloane vor fi doar șiruri de caractere. În schimb, transformându-le în factori, ele vor deveni niveluri ce vor permite metodelor (ex: Naive Bayes) să calculeze probabilități. Una dintre întrebările posibile poate fi: care este probabilitatea de cumpărare în luna noiembrie față de luna februarie?).

3.3. De la logicul <lgl> la Factor:

Variabilele afectate vor fi: **Weekend, Revenue**.

Conversia aceasta este făcută pentru siguranța compatibilității cu funcțiile de analiză a datelor, transformând coloanele din <lgl> în clase de obiecte pentru algoritmi de clasificare.

Astfel, în urma comenzii:

```
info_cumparatori_curatat <- info_cumparatori_curatat %>%
```

```
mutate(across(c(OperatingSystems, Browser, Region, TrafficType, VisitorType,
Month, Weekend, Revenue), as.factor))),
```

variabilele menționate vor fi convertite la factor prin funcția **mutate()**, ajutându-se de **across()**, ceea ce ia la pachet coloanele scrise. Rezultatul final va fi verificat cu **glimpse(info_cumparatori_curatat)** (Fig. 8).

```
Rows: 12,205
Columns: 18
$ Administrative      <dbl> 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 2, 0, 0, 0...
$ Administrative_Duration <dbl> 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...
$ Informational      <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ Informational_Duration <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ ProductRelated      <dbl> 1, 2, 1, 2, 10, 19, 1, 0, 2, 3, 3, 16, 7, 6, 2, 23, 1, ...
$ ProductRelated_Duration <dbl> 0.000000, 64.000000, 0.000000, 2.666667, 627.500000, 15...
$ BounceRates         <dbl> 0.200000000, 0.000000000, 0.200000000, 0.050000000, 0.0...
$ ExitRates           <dbl> 0.200000000, 0.100000000, 0.200000000, 0.140000000, 0.0...
$ PageValues          <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0...
$ SpecialDay          <dbl> 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.4, 0.0, 0.8, 0.4, 0.0, ...
$ Month               <fct> Feb, Feb, Feb, Feb, Feb, Feb, Feb, Feb, Feb, Feb, Feb, ...
$ OperatingSystems     <fct> 1, 2, 4, 3, 3, 2, 2, 1, 2, 2, 1, 1, 1, 2, 3, 1, 1, 1, 2...
$ Browser              <fct> 1, 2, 1, 2, 3, 2, 4, 2, 2, 4, 1, 1, 1, 5, 2, 1, 1, 1, 2...
$ Region              <fct> 1, 1, 9, 2, 1, 1, 3, 1, 2, 1, 3, 4, 1, 1, 3, 9, 4, 1, 1...
$ TrafficType          <fct> 1, 2, 3, 4, 4, 3, 3, 5, 3, 2, 3, 3, 3, 3, 3, 3, 3, 4, 3...
$ VisitorType          <fct> Returning_Visitor, Returning_Visitor, Returning_Visitor...
$ Weekend              <fct> FALSE, FALSE, FALSE, FALSE, TRUE, FALSE, FALSE, TRUE, F...
$ Revenue              <fct> FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, FALSE, ...
```

Fig. 8

4. Al patrulea pas în preprocesarea datelor va fi verificarea valorilor negative, ceea ce înseamnă că vom crea o nouă variabila **erori_logice**, ce va conține duratele din setul de date, iar mai apoi vom vedea dacă există o inconsistență, ceea ce s-a dovedit inexistentă în setul curent de date (Fig. 9).

```
> erori_logice<- info_cumparatori_curatat %>%
+   filter(Administrative_Duration < 0 |
+         Informational_Duration < 0 |
+         ProductRelated_Duration < 0)
> nrow(erori_logice)
[1] 0
```

Fig. 9

5. De asemenea, au fost identificați și câțiva outliers din boxplot-urile pentru cele trei variabile cu durate, dar fiind un număr restrâns au rămas în baza de date pentru pașii următori (Fig 10.1, 10.2, 10.3).

Identificare Outliers: Durata pe paginile de produs




Fig. 10.1

Identificare Outliers: Durata pe paginile administrative




Fig. 10.2

Identificare Outliers: Durata pe paginile informaționale




Fig. 10.3

2.5. Tehnici de vizualizare a datelor

1. Cum va influența valoarea paginii posibilitatea de generare a unui profit?

PageValues vs Revenue





Fig. 11.1.

În Fig. 11.1, comparăm cu cât va afecta valoarea paginii venitul. Variabila **Revenue** împarte utilizatorii ca cei ce au cumpărat (**TRUE**) vs cei ce nu (**FALSE**). **PageValues** este variabila ce măsoară valoarea paginilor vizitate. Cu alte cuvinte, grupul de utilizatori care nu cumpără ceva, va avea o valoare medie mai mică (aproape de 0) decât cei care achiziționează, dar care și petrec mai mult timp pe site.


2. Afectează tipul utilizatorului generarea de profit?



În Fig. 11.2., variabila **Revenue** este, din nou, împărțită în două variante: **TRUE & FALSE**. Scopul diagramei este de a descoperi dacă utilizatorii noi tind să afecteze profitul la fel de mult precum utilizatorii recurenți. În mod instinctiv, am crede că vizitatorii care revin vor genera și mai mult profit, dar asta se dovedește a fi fals. Cei care se întorc pe site au o tendință mult mai mare de a **nu** cumpăra, față de cei noi.

Fig. 11.2.

3. Afectează lunile anului profitul?



În ceea ce privește lunile anului, Fig. 11.3. ne pune la dispoziție discrepanța dintre momentul vizitei și **Revenue**. Este ușor observabil faptul că, într-adevăr, luni precum **mai**, **noiembrie** sau **martie** prezintă un efect asupra cerinței.

Fig. 11.3.

Capitolul 3. Rezultate și discuții

a. Analiza și validarea

Pentru a răspunde la întrebările de cercetare alese, menționate în Capitolul 1, voi folosi două metode de învățare automată: **Naive Bayes** și **Regresia Logistică**, deoarece variabila țintă, **Revenue**, are două clase, **TRUE** și **FALSE**, iar metodele reprezintă o abordare bună în ceea ce privește problemele de clasificare binară.

Naive Bayes: O tehnică care evaluează distribuțiile de probabilitate condiționate și alocă clasa ce optimizează probabilitatea finală. Se fundamentează pe premisa că toate caracteristicile sunt statistic independente.

Regresia Logistică: O metodă ce determină în mod direct probabilitatea ca o instanță să fie parte dintr-o anumită categorie (în cazul nostru, **Revenue = TRUE**) prin utilizarea funcției logistice, care generează valori între 0 și 1.

Pentru a începe procesarea datelor, vom urma următorii pași inițiali:

- **Împărțirea datelor:** Setul de date **info_cumparatori_curatat** a fost împărțit în două subseturi distincte, și anume **train_data(70%)**, folosit pentru învățarea modelelor și **test_data(30%)**, folosit pentru verificarea acurateții pe date noi.

Acest lucru a fost posibil prin crearea unei variabile noi, **split**, unde am stocat rezultatul funcției **initial_split**, în care am definit setul de date de la care plecăm, **prop**(proporția) **70%** pentru datele de antrenament și **strata**.

Stratificarea este bazată pe variabila **Revenue**, pentru a echilibra ponderea dintre cumpărători și non-cumpărători între cele două subseturi, exact așa cum a apărut și în setul de date inițial (Fig 4). Așadar, se poate observa diviziunea ca fiind foarte apropiată de procente inițiale în ambele seturi de date noi (Fig. 12.1., Fig. 12.2.).

Mai apoi, am definit cele două subseturi noi menționate anterior cu ajutorul funcției **training()** și **testing()**.

```
> prop.table(table(train_data$Revenue)) * 100
```

```
FALSE TRUE
84.37134 15.62866
```

Fig. 12.1.

```
> prop.table(table(test_data$Revenue)) * 100
```

```
FALSE TRUE
84.35708 15.64292
```

Fig. 12.2.

- **Cross-validation:** Antrenarea modelelor a fost făcută utilizând metoda **10-fold Cross-Validation** prin funcția **trainControl()**, deoarece este important să minimizăm rata de eroare și să asigurăm o oarece stabilitate a modelului, rezultatul fiind media performanțelor obținute în **10 iterații**. Această procedură împarte setul de antrenament în **10 părți**, antrenează modelul succesiv pe **9** dintre ele și îl testează pe al **10-lea**, repetând acest proces de **10 ori**, iar la final făcând media rezultatelor.


De asemenea, pentru a asigura acuratețea și reproductibilitatea rezultatelor la fiecare rulare de cod, am utilizat funcția **set.seed(123)**.

De asemenea, analizând **matricea de Corelație** cu ajutorul **Corrplot**, am observat relațiile de dependență dintre variabilele numerice, iar cele mai puternice conexiuni se regăsesc între:

- **ProductRelated** și **ProductRelated_Duration**
- **BounceRates** și **ExitRates**
- **Administrative** și **Administrative_Duration**

Acest lucru înseamnă că modelul Naive Bayes va lucra cu variabile ce nu sunt complet independente, sugerând o posibilă redundanță a datelor (Fig. 17).

Fig. 17



b. Implementarea modelului Naive Bayes

Vom începe prin aplicarea metodei de clasificare **Naive Bayes**, pentru a prezice comportamentul vizitatorilor. Precum am menționat anterior, modelul calculează probabilitatea ca o sesiune să aparțină uneia dintre clase (**TRUE/FALSE**), bazându-se pe atributele independente (ex: **PageValues**, **Month**, **VisitorType**) din setul de date.

$$Pr(Y = j | X = x_0)$$

Algoritmul este „naiv”, deoarece pornește de la premisa ca fiecare variabilă este independentă și importantă.

Conform metodologiei din Laboratorul 3-1, având în vedere îmbunătățirea performanței clasificatorului, am realizat un **grid search** cu opțiuni diferite pentru parametrii modelului. Asta

înseamnă că va fi calculat un model pentru fiecare combinație posibilă de opțiuni, iar mai apoi vom alege varianta cu cel mai mare grad al performanței.

Parametrii folosiți în cadrul **grid-ului** sunt (Fig. 13):

```
#create grid
search_grid <- expand.grid( #un tabel cu toate combinatiile posibile
  usekernel = c(TRUE,FALSE), #pt curbe
  fl = 0.5, #plasa de siguranta
  adjust = seq(0,5, by=1) #flexibilitate
)
#antrenarea modelului
mod_nb2 <- train(
  Revenue ~ ., #ghiceste clasa tinta fol toate celelalte coloane din tabel
  #ia toate coloanele, care dintre ele il ajuta sa ghiceasca Revenue
  data=train_data, #din train_data
  method="nb",
  trControl = train_control, #cross-val
  tuneGrid = search_grid #grid
)
```

- **Adjust:** modificarea lățimii de banda a funcțiilor kernel pentru o mai mare flexibilitate în estimare

În urma rulării algoritmului pe cele **8542** de observații din **train_data**, R a generat un raport al performanțelor. În datele când **usekernel** a fost **FALSE**, **acuratețea** a fost **NaN**(not a number), precum și **Kappa**, în fiecare dintre cazurile **adjust(1-5)**. Valorile **NaN** indică faptul că atributele numerice din setul de date(precum **PageValues**) sunt foarte asimetrice și nu pot fi modelate prin distribuția standard Gaussiană. În schimb, când **usekernel** a avut valoarea **TRUE**, cea mai mare acuratețe a avut-o rezultatul cu **adjust=4**, de **0.8438** și **0.0012 Kappa**, cu configurația: **fl = 0.5**, **usekernel = TRUE**, **adjust = 4** (Fig. 14).

Totodată, deși acuratețea de **84.38%** pare promițătoare, consultând **matricea de confuzie** putem observa opusul (Fig. 15):

Astfel, modelul a prezis clasa **FALSE 100%**, chiar dacă realitatea(**Reference**) a fost de **FALSE-84.4%** și **TRUE-15.6%**, ceea ce înseamnă că modelul a observat majoritatea vizitatorilor care nu cumpără, și a decis să ofere **FALSE** pentru toți utilizatorii, deoarece este mai “simplu” să aibă dreptate în **84%** din cazuri, chiar dacă implică și un procent de **15.6%** de nedreptate.

Rularea setului de test cu ajutorul funcției **predict()** și **confusionMatrix()**, **test_data**, reprezintă un ultim pas în formarea unei concluzii în cazul metodei **Naive Bayes**.

Acesta a analizat **3663** de **observații**, noi pentru modelul antrenat. Etapa aceasta reprezintă performanța reală în urma antrenamentului. Rezultatele indică **3089** de **true negative**, unde modelul a prezis corect că **3089** de oameni nu vor cumpăra, dar tot în **prediction False** se află și cei **573** de oameni care, de fapt, se clasează drept cumpărători(**TRUE**) (Fig. 16). O noutate este, totuși, o prezicere de **1** cumpărător, dar această valoare este greșită, și marchează **0** cumpărători adevărați. Deci, deși și în acest caz acuratețea este mare (**84.33%**), valoarea **Kappa** este una negativă ce indică un rezultat foarte

- **Metoda Laplace(fl):** am stabilit o valoare de **0.5** ca plasă de siguranță în cazul în care am avea valori 0
- **Usekernel:** am testat de la **1** la **5(adjust)** rezultatele fără kernel și rezultatele cu kernel

Fig. 13

> mod_nb2
Naive Bayes

8542 samples
17 predictor
2 classes: 'FALSE', 'TRUE'

No pre-processing
Resampling: Cross-Validated (10 fold)
Summary of sample sizes: 7688, 7688, 7687, 7689, 7688, 7688, ...
Resampling results across tuning parameters:

usekernel	adjust	Accuracy	Kappa
FALSE	0	NaN	NaN
FALSE	1	NaN	NaN
FALSE	2	NaN	NaN
FALSE	3	NaN	NaN
FALSE	4	NaN	NaN
FALSE	5	NaN	NaN
TRUE	0	NaN	NaN
TRUE	1	0.8434794	-0.0004659718
TRUE	2	0.8437136	0.0000000000
TRUE	3	0.8437136	0.0000000000
TRUE	4	0.8438307	0.0012630288
TRUE	5	0.8437136	0.0000000000

Tuning parameter 'fl' was held constant at a value of 0.5
Accuracy was used to select the optimal model using the largest value.
The final values used for the model were fl = 0.5, usekernel = TRUE and adjust = 4.
Cross-Validated (10 fold) Confusion Matrix

(entries are percentual average cell counts across re samples)

Reference
Prediction FALSE TRUE
FALSE 84 0
TRUE 0 15
Accuracy (average) 0.8438
Reference
Prediction FALSE TRUE
FALSE 3089 573
TRUE 1 0

Fig. 15

Accuracy : 0.8433
95% CI : (0.8311, 0.8549)
No Information Rate : 0.8436
P-Value [Acc > NIR] : 0.5293

Kappa : -5e-04

Mcnemar's Test P-Value : <2e-16


Sensitivity : 0.9997
Specificity : 0.0000
Pos Pred Value : 0.8435
Neg Pred Value : 0.0000
Prevalence : 0.8436
Detection Rate : 0.8433
Detection Prevalence : 0.9997
Balanced Accuracy : 0.4998

'Positive' Class : FALSE

nesatisfăcător, iar **Specificity** de **0.0000** măsoară capacitatea modelului de a găsi cumpărătorii, ceea ce însumează eșecul metodei Naive Bayes în cazul nostru.

Pentru a înțelege rezultatele din **matricea de confuzie**, am generat **curba ROC**, deoarece graficul evaluează echilibrul dintre **Sensibilitate** (rata de detectare a cumpărătorilor reali) și **Specificitate** (rata de ignorare a non-cumpărătorilor în mod corect). Având în vedere faptul că modelul a decis să seteze **100% FALSE** înseamnă că nicio sesiune nu a reușit să treacă de pragul de **0.5**. Totuși, curba **ROC** demonstrează că modelul a învățat să diferențieze cele două clase, dar probabilitățile atribuite au rămas sub pragul de **0.5** din cauza dezechilibrului din setul de date.

Fig.18



În concluzie, metoda **Naive Bayes** s-a dovedit a nu fi o metodă potrivită pentru setul de date ales, din cauza disproporției dintre clasele **TRUE** și **FALSE**. Modelul nu a reușit să identifice corect cumpărătorii, calculând o probabilitate de cumpărare cu mult sub pragul de **0.5**, cu excepția unui singur caz în rularea **test_data**.

c. Implementarea Regresiei Logistice

Mai departe, am ales **Regresia Logistică** în cautarea unui rezultat mai adecvat în ceea ce privește cele două întrebări ale raportului. Am ales acest model deoarece, în general, dă dovadă de o eficiență crescută, oferind predicția **DA/NU**, având drept avantaj existența coeficienților, care ajută la înțelegerea importanței factorilor.

Conform metodologiei, vom începe prin a verifica structura datelor și a procentelor **FALSE** și **TRUE** din setul de date (Fig. 19, 20).

Pe urmă, am definit modelul în R cu ajutorul funcției **glm()**, unde am folosit ca parametri: **Revenue**, **train_data_** și **family** (Fig. 21).

```
#antrenarea modelului de regresie log, crearea mod
mod_logistic <- glm(Revenue ~ .,
                    data= train_data,
                    family = "binomial")
```

Fig. 21

```
> table(train_data$Revenue)
FALSE TRUE
7207 1335
> prop.table(table(train_data$Revenue))
FALSE TRUE
0.8437134 0.1562866
```

Fig.19




Fig. 20

Din rezultatele obținute cu ajutorul **summary(mod_logistic)**, am identificat cei mai semnificativi factori de pe coloana **Pr(>|z|)**, și anume:

- **PageValues: *** pozitiv**, creșterea valorii paginilor vizitate -> posibilitate profit
- **ExitRates: *** negativ**, cu cât utilizatorul părăsește mai multe pagini -> fără profit
- **Months: ****, lunile **Martie, Mai, Decembrie** prezintă o scădere a probabilității de cumpărare

Cu cât **p** este mic (**sub 0.5**), cu atât șansele sunt mai mici ca să fie doar o simplă coincidență, și valoarea trebuie luată în considerare, iar restul variabilelor reprezintă doar “zgomot”.

Aici va fi menționată și **Rata șanselor (Odd Ratios)**, fiind calculate direct din coeficienții **Regresiei Logistice**, folosind funcțiile **exp(coef())** și **round()**. Valorile mai mari de **1** reprezintă variabilele ce **ajută vânzarea**.

Spre exemplu: **PageValues(1.088)**, **MonthNov(1.446-Black Friday)**, **ExitRates(0.000** – rata de ieșire are un impact negativ asupra vânzării, deci nu ajută deloc), **WeekendTRUE(1.165)**

și **VisitorTypeReturning_Visitor(0.797** – vizitatorii ce se întorc au cu **20%** șanse mai mici să cumpere).

Datorită faptului că modelul a identificat corect în faza de antrenament variabilele importante precum **PageValue** și **ExitRates**, este momentul de a trece la validarea **test_data**.

În urma după rezolvării adiționale a incompatibilităților dintre **train_data2** și **test_data2** prin alinierea nivelelor factorului **Browser**, am generat probabilitățile de conversie pentru setul de test, folosind **head(prob_logistica)**. Aceasta a generat probabilități scăzute pentru primele 6 persoane, ceea ce înseamnă că modelul tinde să clasifice vizitatorii în categoria celor ce nu vor genera un profit (Fig. 22).

```
> head(prob_logistica)
      1      2      3      4
0.0160673606 0.0048411358 0.0004909649 0.0148383333
      5      6
0.0045458829 0.0046841322
```

După aceea, am rulat **pred_logistica_final**, unde am clasificat numerele obținute mai devreme, în **head**, în valori **TRUE/FALSE**, ce respectă pragul de **0.5**. Pentru ca cele două clasificări să nu fie doar un simplu text, le-am transformat în factori(nivele, categorii) cu ajutorul **as.factor()**, ca mai apoi să nu avem erori în **confusionMatrix**, deoarece matricea are nevoie de categorii, nu de cuvinte simple. Rezultatul **matricei de confuzie** este unul satisfăcător (Fig. 23) :

Acuratețea are valoare de **88.12%**, lucru ce înseamnă că modelul clasifică în mod corect **88 din 100** de utilizatori, indicând nu numai o performanță bună, dar și un model stabil.

Regresia a prezis corect că **229** de oameni vor cumpăra și a avut dreptate, dar și că **2998** de oameni **nu** vor cumpăra, ceea ce a fost adevărat. În schimb, avem un fals pozitiv de **91**, dar și un fals negativ de **344**.

Programul R a decis să pună în mod alfabetic **Positive Class** ca fiind **FALSE**, iar de aceea **succesul** este condus de clasa **FALSE** unde acuratețea a fost cea mai mare în predicții. În acest fel, vom citi **Sensitivity** cu valoarea **0.9705** drept capacitatea modelului de a găsi persoanele care **nu** vor cumpăra, iar **Specificity**(ceea ce este, cu adevărat, important), în valoare de **0.3997** este capacitatea modelului de găsire a cumpărătorilor. Asta înseamnă ca adevăratul procentaj ce contează cel mai mult este cel de aproximativ **40%** cumpărători preziși corect.

Confusion Matrix and Statistics

Fig. 23

	Reference	
Prediction	FALSE	TRUE
FALSE	2998	344
TRUE	91	229

Accuracy : 0.8812
 95% CI : (0.8703, 0.8915)
 No Information Rate : 0.8435
 P-Value [Acc > NIR] : 4.646e-11

Kappa : 0.4514

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.9705
 Specificity : 0.3997
 Pos Pred Value : 0.8971
 Neg Pred Value : 0.7156
 Prevalence : 0.8435
 Detection Rate : 0.8187
 Detection Prevalence : 0.9126
 Balanced Accuracy : 0.6851

'Positive' Class : FALSE

Pentru a **optimiza** modelul, o posibilitate este să scădem pragul standard de **0.5** la **0.3** (Fig. 24). Așadar, modelul a identificat acum **326** de persoane care au cumpărat, în loc de precedentul **229**, și **2915** de persoane care nu au cumpărat, față de **2998**. În același timp, numărul de fals negativ a scăzut la **247**, iar cel de fals pozitiv a crescut la **174**. Cu toate că există și unele efecte nefavorabile, aplicarea pragului mai scăzut a dus la o îmbunătățire a modelului, deoarece:

- **Regresia Lineară** a reușit să detecteze încă **97** de clienți converțiți
- **Balanced Accuracy** a crescut de la **68%** la **75.63%**, ceea ce spune despre model că este mai echilibrat și distingerea dintre cele două clase este mai eficientă
- **Specificity** a crescut de la **40%** la **57%**, adică puterea modelului de a indentifica în mod corect utilizatorii care vor genera un profit.

Pentru a evalua performanța globală a **Regresiei Logistice**, am generat **Curba ROC**, cu valoarea **AUC**(Area Under the Curve) de **0.8983** (Fig. 25), valoare ce este foarte apropiată de **1**, ce indică faptul că modelul separă eficient vizitatorii ce vor fi converțiți în cumpărători și cei ce nu vor finaliza nicio comandă. Punctul în care linia roșie se intersectează cu cea albastră este punctul optim.

Pentru a valida statistica și calitatea modelului, mai exact cât de adecvat este acesta pe datele de antrenament, am analizat indicatorii de devianță și criteriul **AIC** (Fig. 26).

Aici putem observa că **Null deviance**-ul (**7405.2** – cât de mare ar fi fost eroarea fără model) devine **Residual deviance** (**4950.4** – cât de mică a ajuns eroarea după model), că valoarea **AIC**-ului de **5084.4** în comparație cu **Null deviance** reprezintă o îmbunătățire semnificativă, dar și că **Fisher Scoring** reprezintă o valoare normală de **14**, reprezentând numărul de recalculări ale R-ului.

În concluzie, modelul **Regresiei Logistice** s-a dovedit a fi o modalitate de predicție eficientă și mai performantă decât **Naive Bayes**. Aceasta a oferit o acuratețe ridicată și a reușit să identifice cumpărătorii reali. De asemenea, prin optimizarea pragului la **0.3**, am reușit să creștem pragul **Specificity** la **57%**, ceea ce indică faptul că business-urile ar trebui să se focuseze pe (Fig. 27):

- **PageValues**, cel mai puternic predictor. Afacerile ar trebui să investească în optimizarea paginilor cu valoare ridicată, adică cele care duc la conversia către cumpărător.

Confusion Matrix and Statistics

Fig. 24

		Reference	
Prediction	FALSE	TRUE	
FALSE	2915	247	
TRUE	174	326	
Accuracy : 0.885			
95% CI : (0.8743, 0.8952)			
No Information Rate : 0.8435			
P-Value [Acc > NIR] : 3.815e-13			
Kappa : 0.5407			
McNemar's Test P-Value : 0.0004497			
Sensitivity : 0.9437			
Specificity : 0.5689			
Pos Pred Value : 0.9219			
Neg Pred Value : 0.6520			
Prevalence : 0.8435			
Detection Rate : 0.7960			
Detection Prevalence : 0.8635			
Balanced Accuracy : 0.7563			
'Positive' Class : FALSE			




Fig. 25

Null deviance: 7405.2	on 8541	degrees of freedom
Residual deviance: 4950.4	on 8475	degrees of freedom
AIC: 5084.4		
Number of Fisher Scoring iterations: 14		

Fig. 26

- **ExitRates** și gestionarea acestora. Este de luat în vedere ceea ce potențialii cumpărători văd și decid să iasă de pe site.
- **Variabile temporale** precum **Month**, unde luni precum **Martie**, **Decembrie** pot îmbunătăți vânzările.




Fig. 27

d. Naive Bayes vs Regresia Logistică

În urma experimentelor realizate, există o comparație clară între modelul **Naive Bayes** și **Regresia Logistică**. Deși ambele au prezentat o acuratețe globală ridicată, asta nu a însemnat neapărat că acuratețea reală este la valori maxime din punct de vedere logic.

Indicator	Naive Bayes	Regresie Logistică(0.3)
Acuratețe globală	84.3%	88.5%
Cumpărători identificați (TRUE Positives)	0	326
Specificacitate(rata de succes pentru clasa TRUE)	0%	56.89%
Balanced Accuracy	50.0%	75.63%
Utilitate business	Scăzută	Ridicată

Punctul slab principal al **Naive Bayes** a fost incapacitatea de a identifica cumpărătorii, având **100%** ca **FALSE**. În contrast, **Regresia** a atins pragul optim de **326** de conversii reale, prin scăderea pragului la **0.3**, arătând astfel diferența de performanță clară dintre cele două metode.

e. Răspunsurile întrebărilor de cercetare

1. În ce măsură vor prezice variabilele de performanță ale paginilor dacă vizitatorii vor genera un venit?

Prin analiza coeficienților în cadrul Regresiei Logistice și a graficului de importanță a variabilelor, avem răspunsul incontestabil că **PageValues** este cea mai importantă și relevantă variabilă în acest studiu de caz și set de date, ea influențând cel mai mult conversia utilizatorilor. Pe scurt, fiecare unitate adăugată valorii va crește posibilitatea ca vizitatorul să devină cumpărător. Pe lângă această variabilă, **ExitRates** dictează, de asemenea, în acest proces al conversiei, sugerând în mod direct că rata de părăsire ridicată reprezintă o amenințare asupra afacerii.

2. Cum influențează profilul vizitatorului și momentul vizitei probabilitatea de a fi săvârșită conversia de la titlul de “simplu oaspete al site-ului” la “cumpărător”? Iar, care dintre acești factori are o importanță mai mare?

Modelul **Regresiei** nu a surprins în mod direct precum graficul importanței variabilelor faptul că **VisitorType-Returning** ar fi unul dintre cei mai importanți factori, având un **p-value** mai ridicat, în schimb **momentul vizitei** obserat prin coloanele **Month/ WeekendTRUE** este unul relevant în această analiză, sezonabilitatea și factorul temporal atrăgând sau îndepărtând persoanele ce pot genera un profit.

4. Concluzie

Acest studiu de caz a demonstrat capacitatea modelelor **Naive Bayes** și **Regresia Logistică** de a lucra pe un set de date complex și amplu, având în vedere dezechilibrul ce l-am păstrat încă de la început pentru acuratețea în rezultate.

Recomandarea pentru orice business care este în situația de a alege între cele două opțiuni este de a merge, bineînțeles, pe varianta regresiei, când vine vorba de acest set de date sau unul similar.

Bibliografie

- Baati, K., & Mohsil, M. (2020). Real-Time Prediction of Online Shoppers' Purchasing Intention Using Random Forest. *16th IFIP International Conference on Artificial Intelligence Applications and Innovations (AIAI)* (pp. 43-51). Neos Marmaras, Grecia: Springer. doi:10.1007/978-3-030-49161-1_4
- Sakar, C. O., Polat, S., Katircioglu, M., & Kastro, Y. (2019). Real-time prediction of online shoppers' purchasing intention using multilayer perceptron and LSTM recurrent neural networks. *Neural Computing and Applications*, 31(10), 6893–6908. doi:10.1007/s00521-018-3523-0
- Sotelo, R. (2024, 12 9). *History of eCommerce: birth and evolution of the selling method that changed the world*. Retrieved from marketing4ecommerce: <https://marketing4ecommerce.net/en/history-of-electronic-commerce/>